# 数据隐私实验报告

魏钊 PB18111699

一 . Samarati 算法

## 1. 问题描述

使用 Samarati (基于二分法) 算法完成 k 匿名。

### 要求:

QI={age, gender, race, marital \_status} (categorical 型), S = {occupation}

输入: data, k, maxSup (data 是数据集, k 是 K-Anonymity 的参数, maxSup 表示最大 suppression 的个数);

输出: 匿名后的数据集。

评价指标:运行时间和 LM

## 2.程序使用指南以及程序分析

在 Saramati 文件夹下在终端执行 main.py 文件。

例如: K=10,Maxsup=20

注意:程序调用了 pandas

程序的输出为 Samarati 文件下的 Final.txt(泛化后的数据), 和终端中打印的三行数据。

三行数据分别为:

划分向量[age,Gender,race, Marital\_status] 注: 0 为不泛化输出原始数据

LM

运行时间

例如:

```
● MINGW64:/c/Users/Lucifer.dark/Desktop/PB18111699_魏钊_Lab1/Sama... — 

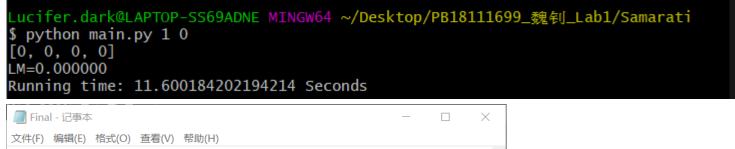
Lucifer.dark@LAPTOP-SS69ADNE MINGW64 ~/Desktop/PB18111699_魏钊_Lab1/Samarati

$ python main.py 10 20
[2, 1, 0, 1]
LM=1.226823
Running time: 16.22192621231079 Seconds
```

相关的程序分析在代码注释中进行了详细的叙述。

## 3. 实验结果分析

K=1,maxSup=0时,数据不泛化,即为原始数据。





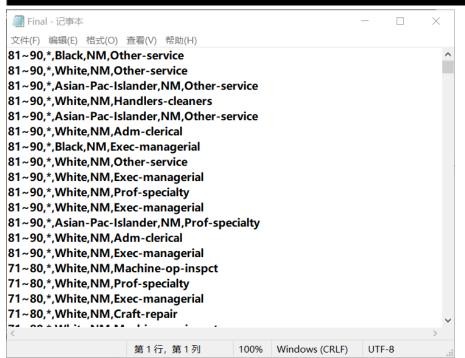
### K=10,maxsup=0 时:

Lucifer.dark@LAPTOP-SS69ADNE MINGW64 ~/Desktop/PB18111699\_魏钊\_Lab1/Samarati \$ python main.py 10 0 [2, 0, 0, 2] LM=1.113924 Running time: 15.087336778640747 Seconds



### K=10, maxSup=20 时:

Lucifer.dark@LAPTOP-SS69ADNE MINGW64 ~/Desktop/PB18111699\_魏钊\_Lab1/Samarati \$ python main.py 10 20 [2, 1, 0, 1] LM=1.226823 Running time: 15.392743825912476 Seconds



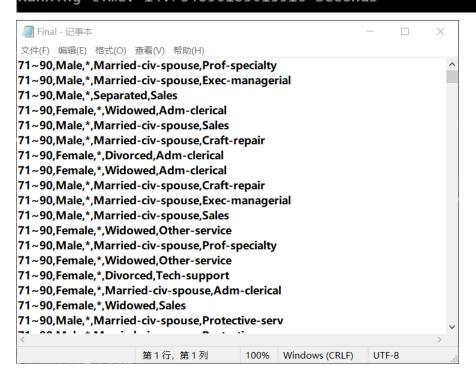
### K=100, maxsup=50 时:

Lucifer.dark@LAPTOP-SS69ADNE MINGW64 ~/Desktop/PB18111699\_魏钊\_Lab1/Samarati \$ python main.py 100 50 [3, 0, 1, 0] LM=1.240506 Running time: 11.940584182739258 Seconds

```
🎒 Final - 记事本
文件(F) 编辑(E) 格式(O) 查看(V) 帮助(H)
71~90, Female, *, Widowed, Adm-clerical
71~90, Female, *, Divorced, Adm-clerical
71~90, Female, *, Widowed, Adm-clerical
71~90, Female, *, Widowed, Other-service
71~90, Female, *, Never-married, Other-service
71~90, Female, *, Widowed, Other-service
71~90, Female, *, Divorced, Tech-support
71~90, Female, *, Married-civ-spouse, Adm-clerical
71~90.Female,*,Widowed,Sales
71~90, Female, *, Married-spouse-absent, Prof-specialty
71~90, Female, *, Married-civ-spouse, Exec-managerial
71~90, Female, *, Widowed, Priv-house-serv
71~90, Female, *, Widowed, Transport-moving
71~90, Female, *, Widowed, Adm-clerical
71~90, Female, *, Widowed, Adm-clerical
71~90, Female, *, Separated, Adm-clerical
71~90, Female, *, Widowed, Priv-house-serv
71~90, Female, *, Widowed, Adm-clerical
                       第1行,第1列
                                          100%
                                                Windows (CRLF)
                                                                  UTF-8
```

K=100, maxsup=200 时:

Lucifer.dark@LAPTOP-SS69ADNE MINGW64 ~/Desktop/PB18111699\_魏钊\_Lab1/Samarati \$ python main.py 100 200 [3, 0, 1, 0] LM=1.240506 Running time: 14.734896183013916 Seconds



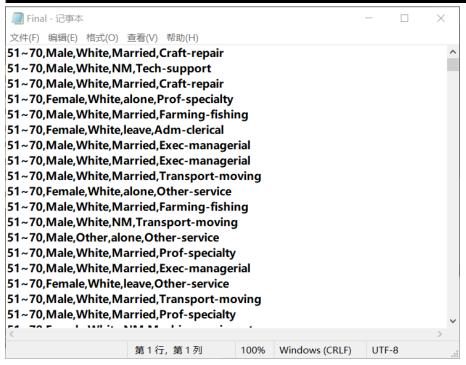
### K=100, maxsup=500 时:

Lucifer.dark@LAPTOP-SS69ADNE MINGW64 ~/Desktop/PB18111699\_魏钊\_Lab1/Samarati \$ python main.py 100 500 [2, 0, 0, 2] LM=1.113924 Running time: 15.541531801223755 Seconds



K=1000, maxsup=500 时:

Lucifer.dark@LAPTOP-SS69ADNE MINGW64 ~/Desktop/PB18111699\_魏钊\_Lab1/Samarati \$ python main.py 1000 500 [3, 0, 0, 1] LM=0.352966 Running time: 17.373523235321045 Seconds



观察上面的测试结果可知:

当 k 不变,maxsup 变大时,运行时间变小,LM 变小(因为可以通过不发布数据来减小泛化深度,因为 maxsup 变大到一定程度,对于不同泛化深度尝试次数减少,运行时间会减少)。

## 4, 讨论与总结

不同的 k 与 maxsup 对算法输出和性能有影响。同时算法理论上来说可以得到很多解满足要求。 而具体的运行时间在不同测试环境下均有一定偏差。

## 二. Mondrian 算法

## 1. 问题描述

使用 Mondrain 算法完成 k 匿名。

## 要求:

QI={age, education\_num} (数值型) , S = {occupation};

输入: data, k, maxSup (data 是数据集, k 是 K-Anonymity 的参数, maxSup 表示最大 suppression 的个数);

输出: 匿名后的数据集。

评价指标:运行时间和LM

## 2.程序使用指南以及程序分析

注:本程序也实现了附加的 Mondrian 算法实现非数值型的泛化只需在修改如下代码 QI colums 处需要泛化的属性即可:

```
# QI 和 S
QI_columns = ['age', 'education_num', 'marital_status', 'sex', 'race']
S_columns = ['occupation', 'class']
```

这里对 age, education\_num,marital\_status,sex,race 进行了泛化, S 集为 occupation,class

在 Mondrian 文件夹下在终端执行 main.py 文件。

例如: K=10



程序的输出为 Mondrian 文件下的 Final.txt(泛化后的数据),和终端中打印的两行数据。

两行数据分别为:

LM

运行时间

相关程序分析,在代码注释中有详细的描述。

## 3. 实验结果分析

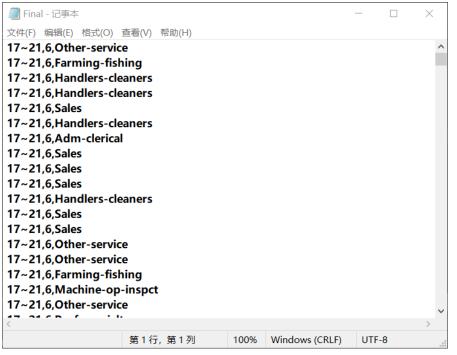
K=1 时:

Lucifer.dark@LAPTOP-SS69ADNE MINGW64 ~/Desktop/PB18111699\_魏钊\_Lab1/Mondrian \$ python main.py 1 LM=0.074191 Running time: 24.020416736602783 Seconds



### K=10 时:





### K=100 时:

Lucifer.dark@LAPTOP-SS69ADNE MINGW64 ~/Desktop/PB18111699\_魏钊\_Lab1/Mondrian \$ python main.py 100 LM=0.111338

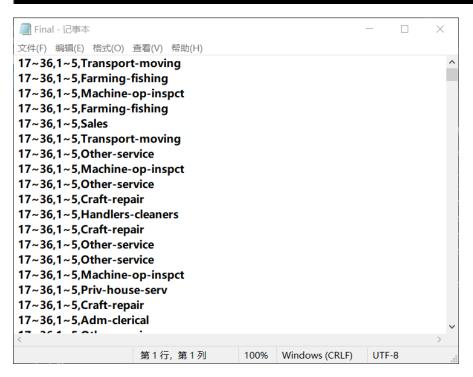
Running time: 23.77035164833069 Seconds



### K=500 时:

Lucifer.dark@LAPTOP-SS69ADNE MINGW64 ~/Desktop/PB18111699\_魏钊\_Lab1/Mondrian \$ python main.py 500 LM=0.233489

Running time: 25.07267737388611 Seconds



### K=1000 时:

Lucifer.dark@LAPTOP-SS69ADNE MINGW64 ~/Desktop/PB18111699\_魏钊\_Lab1/Mondrian \$ python main.py 1000

LM=0.399581

Running time: 25.791969537734985 Seconds



可以看到当 k 增加时, LM 变大。因为 k 越大, 二分的层数就越小, 而 LM (loss 就越大。

### 下面进行选做的测试:

### OI和S集如下:

```
# QI 和 S
QI_columns = ['age', 'education_num', 'marital_status', 'sex', 'race']
S_columns = ['occupation']
```

### 输出格式如下图所示。

### K=1000 时:

■ Final - 记事本

— 文件(F) 編辑(F) 格式(O) 春看(V) 帮助(H)

37~90,1~9,Separated or Never-married or Widowed or Married-AF-spouse ,Female or Male ,Black or White or Other or Asian-Pac-Islander or Amer-Indian-Eskimo ,Other-service 37~90,1~9,Separated or Never-married or Widowed or Married-AF-spouse ,Female or Male ,Black or White or Other or Asian-Pac-Islander or Amer-Indian-Eskimo ,Machine-op-inspct 37~90,1~9,Separated or Never-married or Widowed or Married-AF-spouse ,Female or Male ,Black or White or Other or Asian-Pac-Islander or Amer-Indian-Eskimo ,Other-service 37~90,1~9,Separated or Never-married or Widowed or Married-AF-spouse ,Female or Male ,Black or White or Other or Asian-Pac-Islander or Amer-Indian-Eskimo ,Other-service 37~90,1~9,Separated or Never-married or Widowed or Married-AF-spouse ,Female or Male ,Black or White or Other or Asian-Pac-Islander or Amer-Indian-Eskimo ,Other-service 37~90,1~9,Separated or Never-married or Widowed or Married-AF-spouse ,Female or Male ,Black or White or Other or Asian-Pac-Islander or Amer-Indian-Eskimo ,Other-service 37~90,1~9,Separated or Never-married or Widowed or Married-AF-spouse ,Female or Male ,Black or White or Other or Asian-Pac-Islander or Amer-Indian-Eskimo ,Transport-moving 37~90,1~9,Separated or Never-married or Widowed or Married-AF-spouse ,Female or Male ,Black or White or Other or Asian-Pac-Islander or Amer-Indian-Eskimo ,Transport-moving 37~90,1~9,Separated or Never-married or Widowed or Married-AF-spouse ,Female or Male ,Black or White or Other or Asian-Pac-Islander or Amer-Indian-Eskimo ,Other-service

#### K=10 时:



文件(F) 编辑(E) 格式(O) 查看(V) 帮助(H)

22~36,10~14,Married-spouse-absent or Separated or Widowed ,Female ,Asian-Pac-Islander or Other or Amer-Indian-Eskimo ,Prof-specialty 22~36,10~14,Married-spouse-absent or Separated or Widowed ,Female ,Asian-Pac-Islander or Other or Amer-Indian-Eskimo ,Adm-clerical 22~36,10~14,Married-spouse-absent or Separated or Widowed ,Female ,Asian-Pac-Islander or Other or Amer-Indian-Eskimo ,Other-service 22~36,10~14,Married-spouse-absent or Separated or Widowed ,Female ,Asian-Pac-Islander or Other or Amer-Indian-Eskimo ,Other-service 22~36,10~14,Married-spouse-absent or Separated or Widowed ,Female ,Asian-Pac-Islander or Other or Amer-Indian-Eskimo ,Tech-support 22~36,10~14,Married-spouse-absent or Separated or Widowed ,Female ,Asian-Pac-Islander or Other or Amer-Indian-Eskimo ,Adm-clerical 22~36,10~14,Married-spouse-absent or Separated or Widowed ,Female ,Asian-Pac-Islander or Other or Amer-Indian-Eskimo ,Adm-clerical 22~36,10~14,Married-spouse-absent or Separated or Widowed ,Female ,Asian-Pac-Islander or Other or Amer-Indian-Eskimo ,Prof-specialty

### 三. 选做部分

1. Samarati 算法可能会有很多解满足要求,调研并探究如何选择输出保证结果的可用性尽可能大、说说你的启发。

可以注意到在 Samarati 算法中当取得中间高度的向量组时,不同的枚举方式可以得到不同的向量组顺序,因而得到的第一个满足 k 匿名的向量组有所不同, 所以导致多解性。

通过对比不同枚举顺序导致的发布的数据的差别可以看出,当我们枚举向量组时,可以优先枚举泛化层数小的属性,这样可用性,隐私和 LM 可以得到一个更好的平衡,数据可用性也更大。

抛开数据属性本身的泛化层数和属性范围来说,可以根据实际情况以及不同属性的可用性角度来控制枚举的顺序。比如:对于QI中可能发布后比较敏感的属性,可以最后枚举(这样泛化程度一般更高)或者对于QI中可能一些需要精确发布的属性,可以优先枚举。从而可以通过控制枚举顺序来得到不同的发布数据,在满足同样的 k 匿名的前提下,数据可用性变大。

2.Mondrian 算法处理 categorical,已经在 Mondrian 部分说明过了。